



Εργασία 3 - Υπολογιστική Νοημοσύνη

Στρατάκη Αγγελική

AEM: 10523

email: angeliksi@ece.auth.gr

Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών

Επίλυση προβλήματος παλινδρόμησης με χρήση μοντέλων TSK

Εαρινό εξάμηνο 2025

Περιεχόμενα

1	1. Εφαρμογή σε Απλό Dataset	1
1.1	Διαχωρισμός Dataset σε Υποσύνολα	1
1.2	Ζητούμενα Εργασίας	1
1.3	Δείκτες Απόδοσης Μοντέλων TSK	1
1.4	Αποτελέσματα	2
1.4.1	Μοντέλο TSK 1: 2 input MFs, Singleton output	2
1.4.2	Μοντέλο TSK 2: 3 συναρτήσεις συμμετοχής ανά είσοδο, Singleton έξοδος	5
1.4.3	Μοντέλο TSK 3: 2 input MFs, Polynomial output	7
1.4.4	Μοντέλο TSK 4: 3 συναρτήσεις συμμετοχής ανά είσοδο, Polynomial έξοδος	9
1.5	Αξιολόγηση αποτελεσμάτων εκπαίδευσης	11
1.5.1	1.6 Διαμέριση του Χώρου Εισόδου	12
2	2. Εφαρμογή σε dataset με υψηλή διαστασιμότητα	13
2.1	Διαχωρισμός dataset σε υποσύνολα	13
2.2	Επιλογή των βέλτιστων παραμέτρων	13
2.3	Εκπαίδευση του βέλτιστου μοντέλου TSK	14
2.4	Αποτελέσματα Βέλτιστου Μοντέλου TSK	14
2.5	Παρατηρήσεις	17
	Βιβλιογραφία	18

Κατάλογος σχημάτων

1.1	Συναρτήσεις συμμετοχής μεταβλητών εισόδου 1 ^{ου} μοντέλου TSK πριν την εκπαίδευση	3
1.2	Συναρτήσεις συμμετοχής μεταβλητών εισόδου 1 ^{ου} μοντέλου TSK μετά την εκπαίδευση	3
1.3	Καμπύλες μάθησης 1 ^{ου} μοντέλου TSK	4
1.4	Σφάλμα πρόβλεψης ^{ου} μοντέλου TSK	5
1.5	Συναρτήσεις συμμετοχής εισόδων του 2ου μοντέλου TSK πριν την εκπαίδευση	5
1.6	Συναρτήσεις συμμετοχής εισόδων του 2ου μοντέλου TSK μετά την εκπαίδευση	6
1.7	Καμπύλες μάθησης του 2ου μοντέλου TSK	6
1.8	Σφάλμα πρόβλεψης του 2ου μοντέλου TSK	7
1.9	Συναρτήσεις συμμετοχής μεταβλητών εισόδου 3 ^{ου} μοντέλου TSK πριν την εκπαίδευση	7
1.10	Συναρτήσεις συμμετοχής μεταβλητών εισόδου 3 ^{ου} μοντέλου TSK μετά την εκπαίδευση	8
1.11	Καμπύλες μάθησης 3 ^{ου} μοντέλου TSK	8
1.12	Σφάλμα πρόβλεψης 3 ^{ου} μοντέλου TSK	9
1.13	Συναρτήσεις συμμετοχής εισόδων του 4ου μοντέλου TSK πριν την εκπαίδευση	9
1.14	Συναρτήσεις συμμετοχής εισόδων του 4ου μοντέλου TSK μετά την εκπαίδευση	10
1.15	Καμπύλες μάθησης του 4ου μοντέλου TSK	10
1.16	Σφάλμα πρόβλεψης του 4ου μοντέλου TSK	11
2.1	Μέσο σφάλμα ως συνάρτηση των features_number και r_a	14
2.2	Καμπύλες μάθησης του βέλτιστου μοντέλου TSK	15
2.3	Σφάλμα πρόβλεψης του βέλτιστου μοντέλου TSK	15
2.4	Συναρτήσεις συμμετοχής μεταβλητών εισόδου πριν την εκπαίδευση	16
2.5	Συναρτήσεις συμμετοχής μεταβλητών εισόδου μετά την εκπαίδευση	16

Κατάλογος πινάκων

1.1	Ταξινόμηση μοντέλων προς εκπαίδευση	1
1.2	Τιμές δεικτών απόδοσης των τεσσάρων μοντέλων TSK	11
2.1	Τιμές δεικτών απόδοσης των μοντέλων TSK	16

1. Εφαρμογή σε Απλό Dataset

1.1 Διαχωρισμός Dataset σε Υποσύνολα

Αρχικά, το σύνολο δεδομένων *Airfoil Self-Noise*, το οποίο περιέχει 1503 δείγματα και συνολικά 6 χαρακτηριστικά (5 είσοδοι και 1 έξοδος), χωρίζεται σε τρία ξεχωριστά υποσύνολα. Τα υποσύνολα αυτά είναι:

- **Εκπαίδευσης (Training set):** Χρησιμοποιείται για την αρχική εκπαίδευση των μοντέλων.
- **Επικύρωσης (Validation set):** Αξιοποιείται για τον εντοπισμό πιθανής υπερεκπαίδευσης (overfitting) κατά τη διαδικασία μάθησης.
- **Ελέγχου (Test set):** Εφαρμόζεται στο τέλος για την τελική αξιολόγηση της απόδοσης του εκπαιδευμένου μοντέλου.

Ο διαχωρισμός έγινε με αναλογίες 60% για το σύνολο εκπαίδευσης και 20% για καθένα από τα άλλα δύο σύνολα. Παράλληλα, εφαρμόστηκε και κατάλληλη κανονικοποίηση (προεπεξεργασία) στα δεδομένα μέσω της συνάρτησης `split_scale`.

1.2 Ζητούμενα Εργασίας

Κατόπιν κατάλληλης αρχικοποίησης, ζητείται η εκπαίδευση τεσσάρων διαφορετικών μοντέλων τύπου TSK (Takagi-Sugeno-Kang) και η μεταξύ τους σύγκριση ως προς την ακρίβεια πρόβλεψης.

Ο παρακάτω πίνακας συνοψίζει τα βασικά χαρακτηριστικά των μοντέλων:

Πίνακας 1.1: Ταξινόμηση μοντέλων προς εκπαίδευση

Μοντέλο	Πλήθος Συναρτήσεων Συμμετοχής	Μορφή Εξόδου
TSK_model_1	2	Singleton
TSK_model_2	3	Singleton
TSK_model_3	2	Polynomial
TSK_model_4	3	Polynomial

1.3 Δείκτες Απόδοσης Μοντέλων TSK

Για την αξιολόγηση της ποιότητας των μοντέλων, χρησιμοποιήθηκαν οι εξής δείκτες:

1. **MSE (Mean Squared Error)**: Το μέσο τετραγωνικό σφάλμα μεταξύ της πρόβλεψης του μοντέλου και της πραγματικής τιμής εξόδου.

$$MSE = \sum_{i=1}^N \left(f(x_i) - \hat{f}(x_i) \right)^2$$

2. **RMSE (Root Mean Squared Error)**: Η τετραγωνική ρίζα του MSE.

$$RMSE = \sqrt{MSE}$$

3. **Συντελεστής Προσδιορισμού R^2** : Αντιπροσωπεύει το ποσοστό της διακύμανσης της εξόδου που εξηγείται από το μοντέλο.

$$SS_{\text{res}} = \sum_{i=1}^N (y_i - \hat{y}_i)^2, \quad SS_{\text{tot}} = \sum_{i=1}^N (y_i - \bar{y})^2$$

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$$

4. **NMSE (Normalized Mean Squared Error)**: Ο κανονικοποιημένος δείκτης MSE, υπολογίζεται από το R^2 .

$$NMSE = 1 - R^2$$

5. **NDEI (Normalized Degree of Error Index)**: Δείκτης σφάλματος που προκύπτει από τη ρίζα του NMSE.

$$NDEI = \sqrt{NMSE}$$

1.4 Αποτελέσματα


Η προσομοίωση υλοποιήθηκε στο αρχείο Regression_Part_1.m στη Matlab. Στο αρχικό στάδιο, γίνεται κατάλληλη αρχικοποίηση των τεσσάρων μοντέλων TSK. Στη συνέχεια, με τη βοήθεια μιας επαναληπτικής δομής for, δημιουργείται το αντίστοιχο σύστημα ασαφούς ελέγχου (FIS) για κάθε μοντέλο.

Ακολουθώντας, κάθε μοντέλο εκπαιδεύεται χρησιμοποιώντας τη συνάρτηση anfis, όπου καθορίζονται οι απαραίτητες παράμετροι για τη διαδικασία εκπαίδευσης. Μετά την ολοκλήρωση της εκπαίδευσης, πραγματοποιούνται διαγράμματα για την απεικόνιση της συμπεριφοράς των μοντέλων και υπολογίζονται οι δείκτες απόδοσης, ώστε να αξιολογηθεί η ποιότητα των αποτελεσμάτων.

1.4.1 Μοντέλο TSK 1: 2 input MFs, Singleton output


Στο Σχήμα 1.1 παρουσιάζονται οι μορφές των συναρτήσεων συμμετοχής των μεταβλητών εισόδου του 1^{ου} μοντέλου TSK πριν την εκπαίδευση, ενώ στο Σχήμα 1.2 μετά την εκπαίδευση. Στη συνέχεια, στο Σχήμα 1.3 παρουσιάζονται οι καμπύλες μάθησης του 1^{ου} μοντέλου. Τέλος, στο Σχήμα 1.4 παρουσιάζεται το σφάλμα πρόβλεψης.

Input Membership Functions Before Training - Model 1




Σχήμα 1.1: Συναρτήσεις συμμετοχής μεταβλητών εισόδου 1^{ου} μοντέλου TSK πριν την εκπαίδευση


Input Membership Functions After Training - Model 1



Σχήμα 1.2: Συναρτήσεις συμμετοχής μεταβλητών εισόδου 1^{ου} μοντέλου TSK μετά την εκπαίδευση



Σχήμα 1.3: Καμπύλες μάθησης 1^{ου} μοντέλου TSK




Σχήμα 1.4: Σφάλμα πρόβλεψης^{ον} μοντέλου TSK

1.4.2 Μοντέλο TSK 2: 3 συναρτήσεις συμμετοχής ανά είσοδο, Singleton έξοδος


Στο Σχήμα 1.5 εμφανίζονται οι συναρτήσεις συμμετοχής των εισόδων του δεύτερου μοντέλου TSK πριν από την εκπαίδευση. Αφού ολοκληρωθεί η διαδικασία εκπαίδευσης, το αντίστοιχο σχήμα των τροποποιημένων συναρτήσεων παρουσιάζεται στο Σχήμα 1.6.

Η εξέλιξη του σφάλματος κατά τη διάρκεια της εκπαίδευσης και επικύρωσης αποτυπώνεται στο Σχήμα 1.7, ενώ η απόδοση του μοντέλου στο σύνολο δοκιμών φαίνεται στο Σχήμα 1.8, μέσω της κατανομής του σφάλματος πρόβλεψης.


Input Membership Functions Before Training - Model 2




Σχήμα 1.5: Συναρτήσεις συμμετοχής εισόδων του 2ου μοντέλου TSK πριν την εκπαίδευση



Σχήμα 1.6: Συναρτήσεις συμμετοχής εισόδων του 2ου μοντέλου TSK μετά την εκπαίδευση



Σχήμα 1.7: Καμπύλες μάθησης του 2ου μοντέλου TSK




Σχήμα 1.8: Σφάλμα πρόβλεψης του 2ου μοντέλου TSK


1.4.3 Μοντέλο TSK 3: 2 input MFs, Polynomial output

Στο Σχήμα 1.9 απεικονίζονται οι συναρτήσεις συμμετοχής των μεταβλητών εισόδου του τρίτου μοντέλου TSK πριν ξεκινήσει η εκπαίδευσή του. Αντίστοιχα, το Σχήμα 1.10 δείχνει την τροποποιημένη μορφή αυτών των συναρτήσεων μετά την ολοκλήρωση της εκπαίδευσης.


Οι καμπύλες εκπαίδευσης του μοντέλου εμφανίζονται στο Σχήμα 1.11, ενώ στο Σχήμα 1.12 παρουσιάζεται το σφάλμα πρόβλεψης, όπως υπολογίστηκε με βάση τα δεδομένα δοκιμής.




Σχήμα 1.9: Συναρτήσεις συμμετοχής μεταβλητών εισόδου 3^{ου} μοντέλου TSK πριν την εκπαίδευση



Σχήμα 1.10: Συναρτήσεις συμμετοχής μεταβλητών εισόδου 3^{ου} μοντέλου TSK μετά την εκπαίδευση



Σχήμα 1.11: Καμπύλες μάθησης 3^{ου} μοντέλου TSK




Σχήμα 1.12: Σφάλμα πρόβλεψης 3^{ου} μοντέλου TSK

1.4.4 Μοντέλο TSK 4: 3 συναρτήσεις συμμετοχής ανά είσοδο, Polynomial έξοδος


Στο Σχήμα 1.13 παρουσιάζονται οι αρχικές συναρτήσεις συμμετοχής των εισόδων για το τέταρτο μοντέλο TSK, πριν την έναρξη της εκπαίδευσης. Μετά την προσαρμογή του μοντέλου, οι τροποποιημένες συναρτήσεις συμμετοχής απεικονίζονται στο Σχήμα 1.14.

Οι καμπύλες που προέκυψαν κατά τη φάση της εκπαίδευσης, οι οποίες αποτυπώνουν την εξέλιξη του σφάλματος, φαίνονται στο Σχήμα 1.15. Τέλος, στο Σχήμα 1.16 παρουσιάζεται το σφάλμα πρόβλεψης του μοντέλου στο σύνολο δοκιμής.


Input Membership Functions Before Training - Model 4




Σχήμα 1.13: Συναρτήσεις συμμετοχής εισόδων του 4ου μοντέλου TSK πριν την εκπαίδευση



Σχήμα 1.14: Συναρτήσεις συμμετοχής εισόδων του 4ου μοντέλου TSK μετά την εκπαίδευση



Σχήμα 1.15: Καμπύλες μάθησης του 4ου μοντέλου TSK



Σχήμα 1.16: Σφάλμα πρόβλεψης του 4ου μοντέλου TSK

1.5 Αξιολόγηση αποτελεσμάτων εκπαίδευσης

Στον Πίνακα 1.2 παρουσιάζονται συγκεντρωτικά οι τιμές των δεικτών απόδοσης για τα τέσσερα μοντέλα TSK. Από τη σύγκριση παρατηρείται πως το τρίτο μοντέλο παρουσιάζει τη βέλτιστη απόδοση, διαθέτοντας polynomial έξοδο και δύο συναρτήσεις συμμετοχής ανά είσοδο.

Συγκεκριμένα, αν συγκρίνουμε το μοντέλο TSK 1 με το TSK 2 και αντίστοιχα το TSK 3 με το TSK 4 (όπου τα ζεύγη μοντέλων διαφέρουν μόνο στο πλήθος των συναρτήσεων συμμετοχής), διαπιστώνεται ότι η αύξηση των συναρτήσεων συμμετοχής συνήθως βελτιώνει την απόδοση, εκτός από την περίπτωση του μοντέλου 4, το οποίο αποδίδει χειρότερα από το μοντέλο 3.

Επιπλέον, η χρήση polynomial εξόδου (σε TSK 3 και TSK 4) οδηγεί σε μικρότερο σφάλμα πρόβλεψης σε σχέση με την singleton έξοδο (TSK 1 και TSK 2), με πιο εντυπωσιακά αποτελέσματα στο TSK 3.

Το μοντέλο με την καλύτερη συνολικά επίδοση είναι το TSK 3, με τη μικρότερη τιμή MSE και την υψηλότερη τιμή R^2 .

Πίνακας 1.2: Τιμές δεικτών απόδοσης των τεσσάρων μοντέλων TSK

Model	MSE	RMSE	R^2	NMSE	NDEI
TSK model 1	14.7434	3.8397	0.6621	0.3379	0.5813
TSK model 2	12.2538	3.5005	0.7192	0.2808	0.5299
TSK model 3	7.2531	2.6932	0.8338	0.1662	0.4077
TSK model 4	15.9687	3.9961	0.6340	0.3660	0.6050

Παρατηρείται ότι το *validation error* εμφανίζει μία ταλάντωση μετά από κάποιο αριθμό επαναλήψεων σε κάθε μοντέλο, ενώ το *training error* μειώνεται σταδιακά. Η συμπεριφορά αυτή υποδηλώνει την ύπαρξη υπερεκπαίδευσης, με πιθανή εξαίρεση το πρώτο μοντέλο. Συνεπώς, με

μικρότερο αριθμό εποχών, το τελικό αποτέλεσμα ενδέχεται να είναι συγκρίσιμο χωρίς περιττή επιβάρυνση της διαδικασίας.

1.5.1 1.6 Διαμέριση του Χώρου Εισόδου

Η ανάλυση των μεταβολών στις συναρτήσεις συμμετοχής μετά την εκπαίδευση οδηγεί στα ακόλουθα συμπεράσματα για κάθε μοντέλο:

- **Μοντέλο TSK 1:** Οι συναρτήσεις συμμετοχής μετατοπίζονται σημαντικά, με το δεύτερο ασαφές σύνολο να καλύπτει τον μεγαλύτερο μέρος του εύρους εισόδου στις περισσότερες μεταβλητές, εκτός της τέταρτης.
- **Μοντέλο TSK 2:** Το δεύτερο ασαφές σύνολο υπερσχύει χωρικά, ενώ τα υπόλοιπα μετατοπίζονται. Η κατανομή είναι πιο ισορροπημένη στην τέταρτη μεταβλητή, όπου τα ασαφή σύνολα είναι πιο ομοιόμορφα.
- **Μοντέλο TSK 3:** Το δεύτερο σύνολο κυριαρχεί στις περισσότερες μεταβλητές. Το πρώτο σύνολο περιορίζεται έντονα, εκτός από την πρώτη μεταβλητή, όπου παρατηρείται σχετική ισορροπία.
- **Μοντέλο TSK 4:** Οι πιο αξιοσημείωτες αλλαγές παρατηρούνται στην πρώτη μεταβλητή εισόδου, όπου το πρώτο ασαφές σύνολο σχεδόν εξαφανίζεται. Αντίθετα, το δεύτερο επεκτείνεται στην πέμπτη μεταβλητή.

Γενικότερα, τα ασαφή σύνολα προσαρμόστηκαν σημαντικά κατά τη διαδικασία μάθησης, καθώς τα αρχικά συμμετρικά σύνολα δεν ανταποκρίνονταν επαρκώς στη φύση των δεδομένων. Ως αποτέλεσμα, το τελικό μοντέλο επιτυγχάνει χαμηλότερο σφάλμα πρόβλεψης.

2. Εφαρμογή σε dataset με υψηλή διαστασιμότητα

2.1 Διαχωρισμός dataset σε υποσύνολα

Το σύνολο δεδομένων *Superconductivity*, το οποίο περιλαμβάνει 21 263 δείγματα περιγραφόμενα από 81 χαρακτηριστικά το καθένα, χωρίστηκε σε τρία διακριτά υποσύνολα. Το πρώτο υποσύνολο χρησιμοποιήθηκε για την εκπαίδευση των μοντέλων, το δεύτερο για την επικύρωση και την αποφυγή υπερεκπαίδευσης, ενώ το τρίτο για την τελική αξιολόγηση της απόδοσης.

Ο διαχωρισμός έγινε ως εξής: το 60% των δεδομένων αντιστοιχεί στο υποσύνολο εκπαίδευσης, ενώ τα υπόλοιπα δύο υποσύνολα (επικύρωσης και αξιολόγησης) περιέχουν από 20% το καθένα. Για τη διαδικασία αυτή χρησιμοποιήθηκε η συνάρτηση `split_scale[1]`.

2.2 Επιλογή των βέλτιστων παραμέτρων

Για την εύρεση των βέλτιστων παραμέτρων εκπαίδευσης ενός TSK μοντέλου, ακολουθήθηκε η μέθοδος αναζήτησης πλέγματος (*grid search*). Οι παράμετροι που βελτιστοποιήθηκαν ήταν ο αριθμός χαρακτηριστικών (`features_number`) και η ακτίνα των *clusters* (*ra*), με τις ακόλουθες τιμές:

$$\begin{aligned} \text{features_number} &= [5, 10, 15, 20, 25] \\ \text{ra} &= [0.2, 0.3, 0.4, 0.5, 0.6] \end{aligned}$$

Όλοι οι δυνατοί συνδυασμοί αυτών των τιμών εξετάστηκαν μέσω διπλής επανάληψης `for` στην MATLAB. Για κάθε συνδυασμό εκπαιδεύτηκε ένα μοντέλο τύπου `fis` και υπολογίστηκε το μέσο σφάλμα.

Η επιλογή χαρακτηριστικών από τα συνολικά 81 έγινε με χρήση της συνάρτησης `relieff`, η οποία επιλέγει τα σημαντικότερα χαρακτηριστικά βάσει του αριθμού `features_number`.


Για την αύξηση της αξιοπιστίας των αποτελεσμάτων, χρησιμοποιήθηκε η τεχνική *5-πτυχής διασταυρωμένης επικύρωσης* (*5-fold cross validation*), μέσω της συνάρτησης `cvpartition`. Για κάθε συνδυασμό παραμέτρων, το σύνολο δεδομένων χωριζόταν πέντε φορές με διαφορετικό τρόπο, με 80% να χρησιμοποιείται για εκπαίδευση και 20% για επικύρωση.

Μετά την ολοκλήρωση των πέντε επαναλήψεων για κάθε συνδυασμό, υπολογιζόταν το μέσο σφάλμα και καταχωρούταν σε πίνακα. Ο συνδυασμός με το μικρότερο μέσο σφάλμα θεωρήθηκε ο βέλτιστος. Η διαδικασία αυτή παρουσιάζεται γραφικά στο Σχήμα 2.1, όπου απεικονίζεται το μέσο σφάλμα για κάθε πιθανό ζεύγος τιμών `features_number` και *ra*.

2.3 Εκπαίδευση του βέλτιστου μοντέλου TSK

Με βάση τις βέλτιστες τιμές των παραμέτρων που προσδιορίστηκαν στην προηγούμενη ενότητα, κατασκευάζεται το βέλτιστο μοντέλο TSK κάνοντας χρήση της μεθόδου *subtractive clustering*. Το τελικό μοντέλο εκπαιδεύεται με χρήση των 25 σημαντικότερων χαρακτηριστικών, όπως αυτά επιλέγονται μέσω της συνάρτησης *relieff*, ενώ η ακτίνα των *clusters* ορίζεται ίση με 0.4.

Η διαδικασία εκπαίδευσης και αξιολόγησης του μοντέλου ακολουθεί τα ίδια βήματα με εκείνα που εφαρμόστηκαν στο πρώτο μέρος της εργασίας. Έπειτα από την εκπαίδευση, πραγματοποιείται αξιολόγηση της απόδοσης του μοντέλου σε σύνολα επικύρωσης και ελέγχου, επιτρέποντας τη σύγκριση με προηγούμενα αποτελέσματα και την τεκμηρίωση της επιλογής των βέλτιστων παραμέτρων.




Σχήμα 2.1: Μέσο σφάλμα ως συνάρτηση των `features_number` και r_a


2.4 Αποτελέσματα Βέλτιστου Μοντέλου TSK

Μετά την επιλογή των βέλτιστων παραμέτρων (`features_number` = 25 και ακτίνα clusters r_a = 0.4) μέσω της διαδικασίας αναζήτησης πλέγματος και διασταυρωμένης επικύρωσης 5-πτυχών, εκπαιδεύτηκε το τελικό μοντέλο TSK.


Το μοντέλο κατασκευάστηκε με χρήση της μεθόδου *subtractive clustering* και περιλαμβάνει τα 25 πιο σημαντικά χαρακτηριστικά, όπως αυτά εντοπίστηκαν από τον αλγόριθμο *Relieff*. Η εκπαίδευση πραγματοποιήθηκε σε σύνολο δεδομένων 21263 δειγμάτων, εκ των οποίων το 60% χρησιμοποιήθηκε για εκπαίδευση, το 20% για επικύρωση, και το υπόλοιπο 20% για δοκιμή της απόδοσης του τελικού μοντέλου.




Σχήμα 2.2: Καμπύλες μάθησης του βέλτιστου μοντέλου TSK



Σχήμα 2.3: Σφάλμα πρόβλεψης του βέλτιστου μοντέλου TSK



Σχήμα 2.4: Συναρτήσεις συμμετοχής μεταβλητών εισόδου πριν την εκπαίδευση



Σχήμα 2.5: Συναρτήσεις συμμετοχής μεταβλητών εισόδου μετά την εκπαίδευση

Στον Πίνακα 2.1 παρουσιάζονται οι δείκτες απόδοσης για τα τέσσερα βασικά μοντέλα TSK καθώς και για το βέλτιστο μοντέλο που προέκυψε από την παραμετροποίηση.

Πίνακας 2.1: Τιμές δεικτών απόδοσης των μοντέλων TSK

Model	MSE	RMSE	R^2	NMSE	NDEI
Optimum model	171.8823	13.1104	0.8510	0.1490	0.3860

Παρατηρείται ότι, παρότι το βέλτιστο μοντέλο παρουσιάζει υψηλότερο απόλυτο σφάλμα (MSE, RMSE), διαθέτει τη μεγαλύτερη τιμή R^2 , γεγονός που υποδηλώνει πολύ ισχυρή συσχέτιση μεταξύ των προβλέψεων και των πραγματικών τιμών. Επιπλέον, οι δείκτες NMSE και NDEI είναι χαμηλοί, γεγονός που υποδηλώνει ότι το μοντέλο έχει καλή γενίκευση, ακόμη και με αυξημένη πολυπλοκότητα.

Το υψηλό MSE πιθανότατα οφείλεται στην κλίμακα των τιμών εξόδου στο συγκεκριμένο dataset, και πρέπει να ερμηνεύεται σε συνδυασμό με το R^2 και τον NDEI.

2.5 Παρατηρήσεις

Το βέλτιστο μοντέλο TSK επιτυγχάνεται όταν επιλεγούν 25 χαρακτηριστικά (features) από το σύνολο των 83 διαθέσιμων, με χρήση του αλγορίθμου *Relieff*. Η αύξηση του αριθμού χαρακτηριστικών οδηγεί, γενικά, σε καλύτερη περιγραφή του μοντέλου, καθώς περιλαμβάνει περισσότερη πληροφορία. Παρόλα αυτά, για λόγους απλοποίησης και μείωσης του αριθμού των κανόνων *IF-THEN*, θα μπορούσε να επιλεγεί μικρότερος αριθμός χαρακτηριστικών (π.χ., 15), με μικρή μόνο επιβάρυνση στο μέσο σφάλμα.

Παρατηρείται διαφορά στους δείκτες απόδοσης μεταξύ των μοντέλων του πρώτου και του δεύτερου μέρους της εργασίας. Πιο συγκεκριμένα, το *Root Mean Square Error* (RMSE) είναι υψηλότερο στο δεύτερο μέρος, γεγονός που μπορεί να αποδοθεί στην προσέγγιση που ακολουθείται. Ενώ στο πρώτο μέρος γίνεται λεπτομερής μοντελοποίηση με καθορισμένη δομή, στο δεύτερο μέρος η περιγραφή των μοντέλων είναι προσεγγιστική, λόγω της αυτόματης επιλογής χαρακτηριστικών και της χρήσης clustering.

Η μέθοδος *subtractive clustering* επιλέχθηκε στο δεύτερο μέρος λόγω της μεγάλης διασποράς των δεδομένων, καθώς η χρήση *grid partitioning* σε τέτοια σύνολα είναι υπολογιστικά απαγορευτική. Ωστόσο, η επιλογή αυτή επηρέασε την απόδοση των μοντέλων, καθώς η *subtractive clustering* οδηγεί σε λιγότερο εκφραστικά σύνολα κανόνων.

Τέλος, όπως αναμενόταν, παρατηρήθηκε σημαντική μεταβολή στα ασαφή σύνολα μετά την εκπαίδευση του μοντέλου. Αυτό υποδεικνύει ότι τα αρχικά συμμετρικά σύνολα δεν περιέγραφαν επαρκώς το πρόβλημα και απαιτήθηκε προσαρμογή των παραμέτρων για τη βελτίωση της ακρίβειας πρόβλεψης.

Βιβλιογραφία

1. Υλικό Μαθήματος Υπολογιστική Νοημοσύνη, ΤΗΜΜΥ ΑΠΘ, Θεοχάρης Ιωάννης, Ιούλιος 2025.
2. Timothy J. Ross, *Fuzzy Logic with Engineering Applications*, 4η Έκδοση, Wiley, 2016.
3. MathWorks, “MATLAB Documentation,” <https://www.mathworks.com/help/fuzzy/anfis.html>
4. J.-S. R. Jang, “ANFIS: Adaptive-Network-Based Fuzzy Inference System,” *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 23, no. 3, 1993.
5. Wang, L.-X., *A Course in Fuzzy Systems and Control*, Prentice Hall, 1997.
6. Timothy J. Ross, *Fuzzy Logic with Engineering Applications*, 4η Έκδοση, Wiley, 2016.